

Warszawa, 25.01.2022



**Wektorowy Model Korekty Błędem (VECM) do zbadania relacji między cenami surowców  
a produkcją przemysłową w Stanach Zjednoczonych**

Przedmiot: Ekonometria Szeregów Czasowych

Projekt wykonali:

Aleksandra Struk, 108020

Mikołaj Maślanka, 108279

## 1. WSTĘP

Wybuch COVID-19 spowodował bezprecedensowo negatywne skutki we wszystkich branżach, przy czym najbardziej ucierpiała produkcja. W pierwszym półroczu 2020 r. nastąpił ogromny spadek aktywności produkcji przemysłowej, ponieważ wiele fabryk zostało zamkniętych lub zmuszonych do pracy przy ograniczonych zdolnościach produkcyjnych. Oprócz tych problemów producenci musieli również zmagać się z niedoborami materiałów, wahania cen surowców wpłynęły również na podaż, koszty produkcji, a co za tym idzie decyzję o produkcji. Niemniej jednak relacje między cenami energii i metali mogą być jeszcze bardziej skomplikowane, nie tylko ze względu na ich wielokierunkowe powiązania, ale także ze względu na występowanie efektów opóźnionych w czasie, równowagi krótko- i długookresowej. W tej pracy spróbujemy zastosować Wektorowy Model Korekty błędem (VECM) do (1) zbadania relacji między cenami towarów a produkcją przemysłową w Stanach Zjednoczonych oraz (2) prognozowania zmian produkcji przemysłowej i cen towarów w najbliższej przyszłości. Ramy czasowe: od stycznia 1990 do lipca 2021.

Źródło danych o cenach towarów: strona internetowa Banku Światowego poświęconej rynkom towarowym. Wybraliśmy po dwóch przedstawicieli energetyki i metali przemysłowych: (1) Energia: ropa naftowa, gaz ziemny; (2) Metale przemysłowe — aluminium, miedź

Źródło danych o Indeksie Produkcji Przemysłowej: strona internetowa Amerykańskiego Banku Rezerwy Federalnej.

## TEORIA EKONOMICZNA

Trzy główne surowce energetyczne – węgiel, ropa naftowa oraz gaz ziemny – są obecnie wykorzystywane do produkcji 87% energii na świecie. Nie dziwi zatem, że naukowcy od dawna usiłują badać i ujawniać mechanizmy zmian cen surowców energetycznych ale i również metali przemysłowych. W tego typu pracach bada się przede wszystkim zależności przyczynowe pomiędzy ceną surowców a gospodarką, na którą składa się między innymi wielkość produkcji przemysłowej, która będzie zmienną w naszym projekcie. Teorie ekonomii sugerują, że między zmiennymi ekonomicznymi istnieje równowaga długookresowa, która może czynić te zmienne stacjonarnymi bez uwzględniania różnic i jest to tzw. kointegracja.


Wektorowy model korekty błędów (VECM) służy jako sposób na uchwycenie takich długookresowych relacji równowagi (poziomów) na szczycie relacji krótkookresowych (różnic).

## 2. MODELOWANIE

### 2.1. Badanie stacjonarności

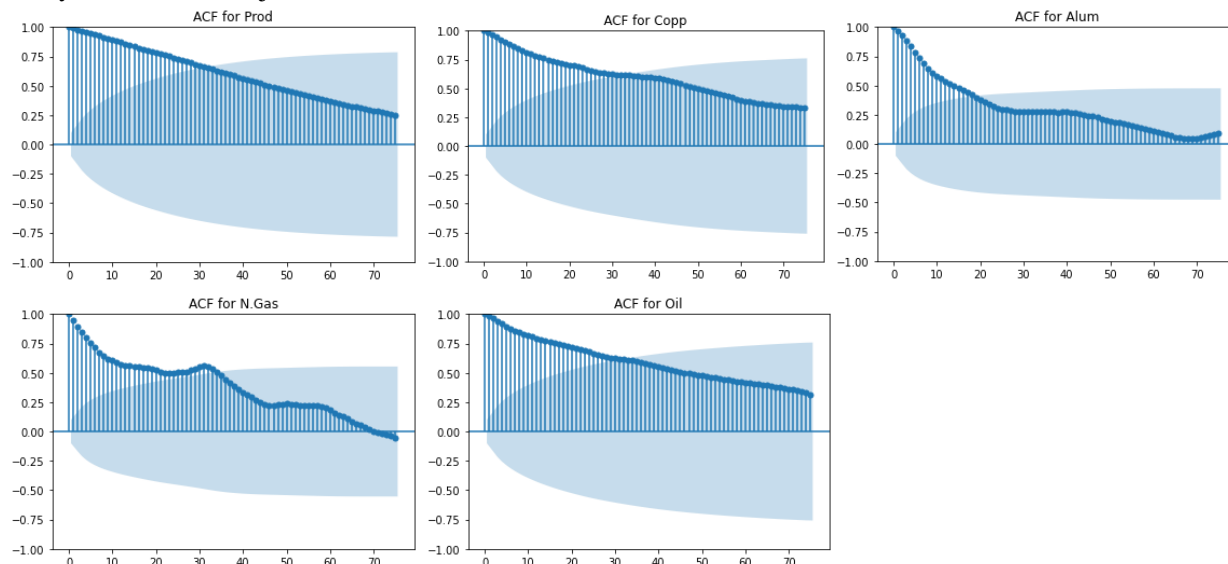
Przed zastosowaniem VECM zbadamy, czy dane szeregów czasowych są stacjonarne, co oznacza, że wariancja szeregu czasowego nie jest zależna od czasu. Jeśli szereg czasowy jest nieruchomy, wykres będzie wyglądał jak biały szum.

Z poniższego wykresu liniowego niezróżnicowanych szeregów czasowych i macierzy korelacji wynika, że prawdopodobnie są one niestacjonarne i występują między nimi kointegracje.



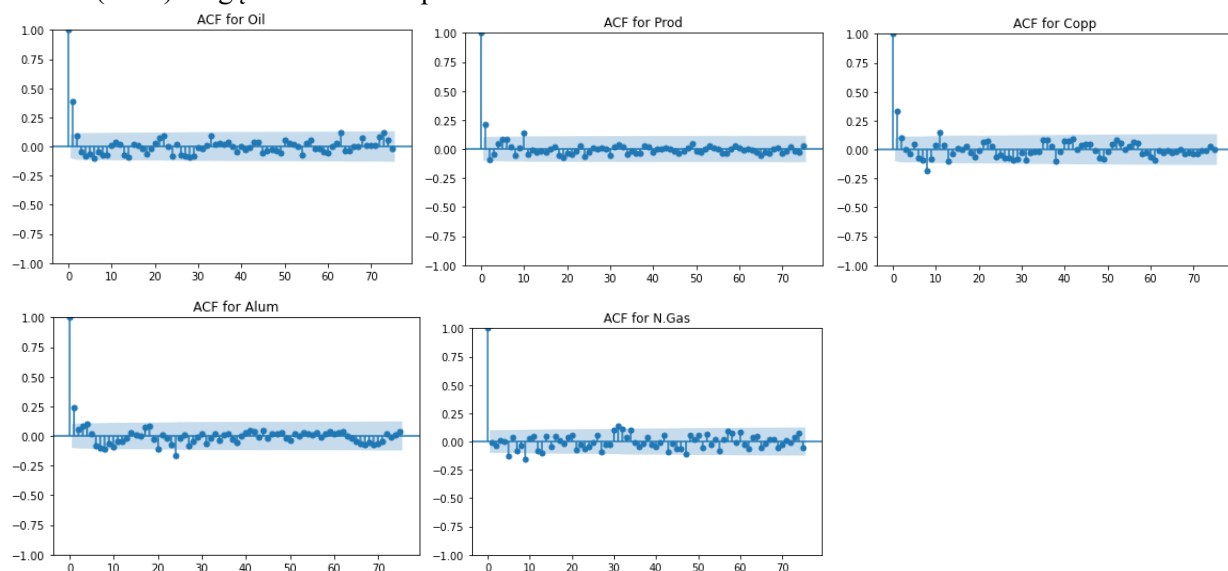
### 2.4. Analiza funkcji autokorelacji (ACF) zmiennych niezróżnicowanych

Z poniższych 5 wykresów funkcji autokorelacji dla niezróżnicowanych szeregów czasowych, wynika są one zdecydowanie niestacjonarne.



### 2.3. Analiza funkcji autokorelacji zmiennych różnicowych

Jeśli wykonamy wykres na zmiennych po pierwszej różnicy, ACF zmiennych różnicowych wyglądają na potencjalnie stacjonarne. Sugeruje to, że każdy szereg czasowy jest stacjonarne I(1). Rozszerzone testy Dickeya-Fullera (ADF) mogą to dodatkowo potwierdzić.



### 2.4. Rozszerzony test Dickeya-Fullera dla zmiennych różnicowych — test stacjonarny

Hipoteza zerowa mówi, że dane są niestacjonarne. Zatem jeśli wartości p są niskie, dane są stacjonarne i mają wysoką istotność statystyczną.

Wyniki testów ADF dla zmiennych różnicujących silnie wspierają hipotezę, że szeregi czasowe są stacjonarne.

### 2.5. Test przyczynowości Grangera — test na związki przyczynowe

Następnie chcielibyśmy sprawdzić, czy istnieją związki przyczynowe między szeregami czasowymi za pomocą testu przyczynowości Grangera. Jeśli wartość p jest mała, możemy odrzucić hipotezę zerową, że opóźnione X mają moc predykcyjną dla przyszłego Y.

Poniżej przedstawiono wyniki testów na indeksie produkcji przemysłowej. Wyniki pokazują, że wszystkie ceny surowców, mają moc predykcyjną dla produkcji przemysłowej USA, jedynie cena gazu ziemnego wykazuje wyższe wartości p, ale nie decydujemy się usunąć jej z modelu.

Does a lag of Oil predict Prod	Does a lag of N.Gas predict Prod	Does a lag of Alum predict Prod
Granger Causality number of lags (no zero) 1 ssr based F test: F=0.1820 , p=0.6699 , df_denom=380, df_num=1 ssr based chi2 test: chi2=0.1835 , p=0.6684 , df=1 likelihood ratio test: chi2=0.1834 , p=0.6684 , df=1 parameter F test: F=0.1820 , p=0.6699 , df_denom=380, df_num=1	Granger Causality number of lags (no zero) 1 ssr based F test: F=0.3820 , p=0.5829 , df_denom=380, df_num=1 ssr based chi2 test: chi2=0.3044 , p=0.5811 , df=1 likelihood ratio test: chi2=0.3043 , p=0.5812 , df=1 parameter F test: F=0.3820 , p=0.5829 , df_denom=380, df_num=1	Granger Causality number of lags (no zero) 1 ssr based F test: F=0.4062 , p=0.5243 , df_denom=380, df_num=1 ssr based chi2 test: chi2=0.4094 , p=0.5223 , df=1 likelihood ratio test: chi2=0.4092 , p=0.5224 , df=1 parameter F test: F=0.4062 , p=0.5243 , df_denom=380, df_num=1
Granger Causality number of lags (no zero) 2 ssr based F test: F=18.5486 , p=0.0000 , df_denom=377, df_num=2 ssr based chi2 test: chi2=37.5892 , p=0.0000 , df=2 likelihood ratio test: chi2=35.8528 , p=0.0000 , df=2 parameter F test: F=18.5486 , p=0.0000 , df_denom=377, df_num=2	Granger Causality number of lags (no zero) 2 ssr based F test: F=2.4836 , p=0.0848 , df_denom=377, df_num=2 ssr based chi2 test: chi2=5.0330 , p=0.0807 , df=2 likelihood ratio test: chi2=5.0002 , p=0.0821 , df=2 parameter F test: F=2.4836 , p=0.0848 , df_denom=377, df_num=2	Granger Causality number of lags (no zero) 2 ssr based F test: F=4.3593 , p=0.0134 , df_denom=377, df_num=2 ssr based chi2 test: chi2=8.0343 , p=0.0121 , df=2 likelihood ratio test: chi2=8.7337 , p=0.0127 , df=2 parameter F test: F=4.3593 , p=0.0134 , df_denom=377, df_num=2
Granger Causality number of lags (no zero) 3 ssr based F test: F=12.6351 , p=0.0000 , df_denom=374, df_num=3 ssr based chi2 test: chi2=38.6148 , p=0.0000 , df=3 likelihood ratio test: chi2=36.7809 , p=0.0000 , df=3 parameter F test: F=12.6351 , p=0.0000 , df_denom=374, df_num=3	Granger Causality number of lags (no zero) 3 ssr based F test: F=2.1737 , p=0.0907 , df_denom=374, df_num=3 ssr based chi2 test: chi2=6.6433 , p=0.0842 , df=3 likelihood ratio test: chi2=6.5860 , p=0.0863 , df=3 parameter F test: F=2.1737 , p=0.0907 , df_denom=374, df_num=3	Granger Causality number of lags (no zero) 3 ssr based F test: F=4.1919 , p=0.0062 , df_denom=374, df_num=3 ssr based chi2 test: chi2=12.8112 , p=0.0051 , df=3 likelihood ratio test: chi2=12.6005 , p=0.0056 , df=3 parameter F test: F=4.1919 , p=0.0062 , df_denom=374, df_num=3
Does a lag of Copp predict Prod		
Granger Causality number of lags (no zero) 1 ssr based F test: F=1.2743 , p=0.2597 , df_denom=380, df_num=1 ssr based chi2 test: chi2=1.2844 , p=0.2571 , df=1 likelihood ratio test: chi2=1.2822 , p=0.2575 , df=1 parameter F test: F=1.2743 , p=0.2597 , df_denom=380, df_num=1		
Granger Causality number of lags (no zero) 2 ssr based F test: F=7.0361 , p=0.0010 , df_denom=377, df_num=2 ssr based chi2 test: chi2=14.2588 , p=0.0008 , df=2 likelihood ratio test: chi2=13.9991 , p=0.0009 , df=2 parameter F test: F=7.0361 , p=0.0010 , df_denom=377, df_num=2		
Granger Causality number of lags (no zero) 3 ssr based F test: F=5.4467 , p=0.0011 , df_denom=374, df_num=3 ssr based chi2 test: chi2=16.6460 , p=0.0008 , df=3 likelihood ratio test: chi2=16.2926 , p=0.0010 , df=3 parameter F test: F=5.4467 , p=0.0011 , df_denom=374, df_num=3		

### 2.6 Johansen Cointegration Test — Test na kointegrację

W kolejnym kroku zbadamy, czy między szeregami czasowymi istnieją relacje kointegracji (długookresowe) wg testu kointegracji Johansena.

Using the Trace Test, there are 1 cointegrating vectors at 1 lags between the series
Using the Trace Test, there are 1 cointegrating vectors at 2 lags between the series
Using the Trace Test, there are 1 cointegrating vectors at 3 lags between the series
Using the Trace Test, there are 1 cointegrating vectors at 4 lags between the series
Using the Trace Test, there are 0 cointegrating vectors at 5 lags between the series
Using the Trace Test, there are 1 cointegrating vectors at 6 lags between the series

Wyniki tego testu pokazują, że istnieją zależności kointegrujące 1 między szeregami odpowiednio przy 1, 2, 3, 4 i 6 opóźnieniach. Ponadto istnieje 0 zależności kointegrujących między szeregami czasowymi przy 5 opóźnieniach w okresie próby na poziomie istotności 95%.

### 3. VECM

Współczynniki ładujące (alfa) pokazują, jak szybko szeregi czasowe zbliżają się do relacji równowagi długookresowej.

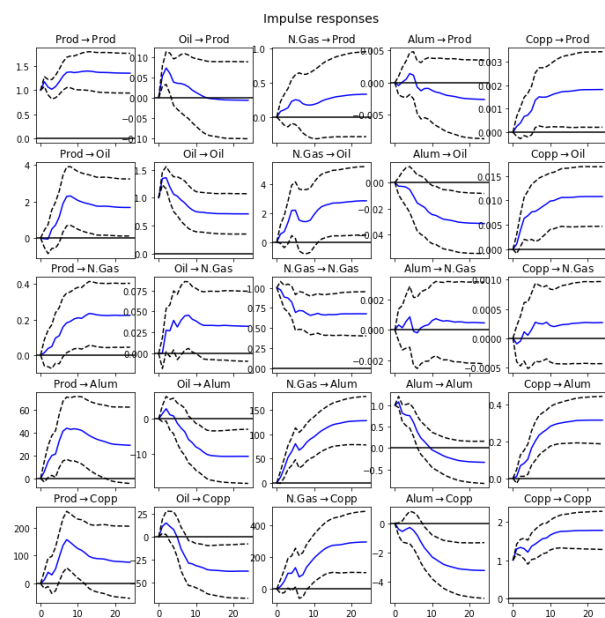
Loading coefficients (alpha) for equation Prod						
	coef	std err	z	P> z	[0.025	0.975]
ec1	0.0002	0.000	0.455	0.649	-0.001	0.001
Loading coefficients (alpha) for equation Oil						
	coef	std err	z	P> z	[0.025	0.975]
ec1	-0.0031	0.002	-1.918	0.055	-0.006	6.68e-05
Loading coefficients (alpha) for equation N.Gas						
	coef	std err	z	P> z	[0.025	0.975]
ec1.N	0.0004	0.000	1.601	0.109	-9.08e-05	0.001
Loading coefficients (alpha) for equation Alum						
	coef	std err	z	P> z	[0.025	0.975]
ec1	-0.1867	0.031	-5.933	0.000	-0.248	-0.125
Loading coefficients (alpha) for equation Copp						
	coef	std err	z	P> z	[0.025	0.975]
ec1	-0.4758	0.106	-4.491	0.000	-0.683	-0.268
Cointegration relations for loading-coefficients-column 1						
	coef	std err	z	P> z	[0.025	0.975]
beta.1	1.0000	0	0	0.000	1.000	1.000
beta.2	798.00	1.962	4.285	0.000	4.563	12.255
beta.3	-117.5335	18.237	-6.445	0.000	-153.277	-81.790
beta.4	0.8703	0.139	6.239	0.000	0.597	1.144
beta.5	-0.1890	0.034	-5.610	0.000	-0.255	-0.123
const	-763.4656	135.408	-5.638	0.000	-1028.860	-498.071

Współczynniki beta to rzeczywiste długookresowe współczynniki relacji. Beta dla amerykańskiego indeksu produkcji przemysłowej jest standaryzowana na poziomie 1, aby ułatwić interpretację innych współczynników beta. Wśród wszystkich, beta dla ceny gazu ziemnego wynosi -117,5335, co oznacza, że wzrost ceny gazu ziemnego o 1 dolara spowodowałby w długim okresie spadek indeksu produkcji przemysłowej USA o 117,5335. Podobnie beta dla ceny miedzi wynosi -0,1890.

W przeciwieństwie do tego, beta dla ceny ropy naftowej wynosi 798, co oznacza, że wzrost ceny rudy żelaza o 1 dolara doprowadziłby w dłuższej perspektywie do wzrostu indeksu produkcji przemysłowej USA o 798. Podobnie beta dla ceny aluminium wynosi 0,8703

### 3.1. Reakcja na impuls

Funkcja odpowiedzi impulsowej (IRF) pokazuje reakcję jednej zmiennej, gdy inna lub ta sama zmienna jest szokowana wzrostem o 1 jednostkę w poprzednim okresie (miesiącu). Niebieska krzywa pokazuje efekt szoku jednostkowego w miarę upływu czasu, a kropkowane linie reprezentują 95% przedział ufności dla IRF. Tutaj staramy się obserwować reakcję impulsową przez okres 24 miesięcy.



Skupmy się na IRF dla amerykańskiego indeksu produkcji przemysłowej.


Z pierwszej kolumny powyższego wykresu warto zauważyć, że jeśli Indeks Produkcji Przemysłowej doznał szoku ze wzrostem o 1 jednostkę w poprzednim miesiącu, ceny wszystkich towarów wzrosną. Ta obserwacja może być poparta logiką szoków popytowych.

Po drugie, z pierwszego rzędu powyższego wykresu widzimy, że jednojednostkowy pozytywny szok cen ropy naftowej, gazu ziemnego i miedzi doprowadziłby do wzrostu produkcji przemysłowej, choć w różnym zakresie i czasie trwania.

Po trzecie, negatywny wpływ na Wskaźnik Produkcji Przemysłowej, gdy ceny aluminium doświadczają pozytywnego szoku o jedną jednostkę. Wzrost cen tych surowców może prowadzić do wyższych kosztów nakładów w sektorach wytwórczych, a tym samym utrudnić produkcję przemysłową.

#### 4.PROGNOZOWANIE

Na koniec, poniżej znajduje się dynamiczny wykres prognostyczny indeksu produkcji przemysłowej w USA i cen surowców na nadchodzący rok.



#### Wnioski

1. Produkcja przemysłowa jest trudna do ożywienia w krótkim okresie i może nawet nieco dalej spadać. Relatywnie słaby trend prawdopodobnie utrzyma się przez dłuższy czas.
2. Funkcja reakcji na impuls daje wyniki zgodnie z naszymi oczekiwaniami, które dalej mają uzasadnienie w teorii ekonomii.